



VANESSA KENNICHE SANOCKA

Ingénieur Data & Machine Learning



KENSAN.VAN@GMAIL.COM | +33 7 68 14 01 74 | vanessa-kenniche-sanocka.github.io

Paris & Saint-Germain-en-Laye – Français natif, Polonais natif, Anglais C1 (TOEIC)

Expertise

Ingénierie appliquée aux politiques publiques. Conception et maintenance de pipelines data de bout en bout, indexation RAG avec déploiement conteneurisé, industrialisation de modèles ML dans le respect des exigences de traçabilité, de sécurité et de conformité propres aux institutions publiques. Modélisation économétrique, solutions de visualisation intégrées au système d'information et restitution d'analyses complexes en outils accessibles aux équipes métier.

Compétences

Langages & Frameworks : Python, SQL, R, Bash, PostgreSQL, Elasticsearch, Airflow, Next.js, Quarto	MLOps & Data : RAG, MLflow, Scikit-learn, PyTorch, TensorFlow, LangChain, Panel & geospatial data	DevOps & Outils: Docker, Linux, Git/GitLab CI, Apache Superset, Spark, FastAPI, Streamlit, CASD, QGIS
--	--	--

Expérience professionnelle – Cour des Comptes

Data Engineer Nov 2025 – Aujourd'hui

► **PRISME - Pipeline RAG sur le corpus documentaire** : indexation Elasticsearch et recherche hybride sur ~35 000 publications de la Cour, chaîne complète de parsing, chunking hiérarchique, calcul d'embeddings denses, reranking par cross-encoder et génération via modèles de langage hébergés en interne, avec interface Next.js / FastAPI. Évaluation par benchmark gold standard, avec déploiement Docker multi-services orchestré via registre interne.

► **ANAPAYE - Pipeline data & ML paie publique territoriale** : migration depuis ETL Talend legacy vers une architecture conçue et maintenue en Python avec parsing XML stream (XHL/PES v2) et PostgreSQL multi-schémas géré par Alembic, restitution analytique sous Apache Superset embarqué par SDK avec RLS dynamique à destination des équipes d'instruction, volet Machine Learning de détection d'anomalies en cours d'industrialisation sous MLflow.

Data Scientist Nov 2023 – Nov 2025

► **Évaluation économétrique de politiques publiques** : modélisation des politiques tarifaires des transports urbains par panel et event study (données GART/CEREMA), étude par sondage avec redressement (score de propension, calage sur marges, bootstrapping) enrichie par FILOSOFI, restitution Shiny ; évaluation de la loi PACTE par statistiques descriptives et régressions prédictives sur base POTE, FELIN et ERFS.

► **Analyses d'appui aux contrôles** : modélisation prédictive ML sur registres judiciaires confidentiels (CASD), analyse de survie et scoring de risque pour la décision publique en matière carcérale ; harmonisation SIG France-Suisse avec la Cour des comptes Suisse, identification des discontinuités réglementaires transfrontalières et restitution en visualisations et recommandations.

Expérience académique et personnelle – Coursus Master Ingénierie Data Science for Social Sciences, Université Paris Nanterre, 2020-2025

► **Projets d'ingénierie, data & ML** : détection de pricing algorithmique de marché (avec le laboratoire EconomiX) par scraping haute fréquence vers datalake et estimation des ajustements de prix ; détection de fraude bancaire par modélisation supervisée sur données déséquilibrées (SMOTE/B-SMOTE, validation croisée) ; système Power BI démographique sur entrepôt en étoile MySQL avec requêtes à fenêtre glissante pour tableau de bord territorial.

► **Projets de modélisation & analyse** : benchmarking économétrique cross-country des déterminants d'innovation (logit/Poisson, régularisation Lasso) ; analyse de réseau des votes parlementaires par scraping opendata, matrices de distance et clusters pour identifier les coalitions transpartisanes ; cartographie statistique et géospatiale des risques concurrentiels sur brevets PATSTAT pour recommandations de politique industrielle.

Informations additionnelles

- **Ambassadrice pour le plan STEM "Filles et Maths"** sensibilisation de lycéennes aux carrières scientifiques.
- Veille technique, conception d'outils formation et plateforme collaborative pour équipe de Data Scientists.